

Teste de Desempenho Contínuo, Orientado Por Rastreamento Ocular

Amanda de Oliveira Costa¹, Arthur Ribeiro Dias Fudali²,
Diego Baltazar de Souza Claudio³, Giovana da Silva Albanês Santos⁴, Igor Leite Gomes⁵

¹Faculdade de Tecnologia do Estado de São Paulo

*amanda.costa5@aluno.cps.sp.gov.br, arthur.fudali@aluno.cps.sp.gov.br
diego.claudio@aluno.cps.sp.gov.br, giovana.santos10@aluno.cps.sp.gov.br
igor.gomes2@aluno.cps.sp.gov.br*

Resumo

O Transtorno de Déficit de Atenção com Hiperatividade (TDAH) é uma condição neuropsicológica que pode afetar significativamente o desempenho de crianças em diversas esferas da vida, como estudos e relações interpessoais. O diagnóstico tradicional envolve avaliações clínicas e testes padronizados, os quais nem sempre estão disponíveis de forma acessível ou apresentam dados objetivos suficientes para um rastreio inicial eficaz. Este estudo propõe uma abordagem tecnológica que integra uma plataforma digital gamificada, baseada no Teste de Desempenho Contínuo (TDC), com técnicas de rastreamento ocular em tempo real. A proposta tem como objetivo identificar possíveis indícios de TDAH em crianças de 10 a 12 anos por meio da análise de desempenho atencional durante a execução de tarefas gamificadas. O sistema registra dados como acertos, tempo de reação, erros de omissão e comissão, variabilidade nas respostas e padrões de fixação ocular, os quais são processados automaticamente. Com base na comparação entre os dados coletados e o banco de dados, o sistema fornece um feedback interpretativo ao usuário, podendo contribuir como ferramenta complementar de triagem inicial. A acessibilidade da plataforma, que roda diretamente no navegador, e seu caráter lúdico e autônomo tornam a solução promissora para ampliar o acesso ao rastreamento precoce de indícios do transtorno. A proposta está alinhada ao terceiro Objetivo de Desenvolvimento Sustentável (ODS) da Agenda 2030 da ONU, que visa garantir saúde e bem-estar para todas as pessoas, promovendo inovações tecnológicas para uma saúde mais inclusiva, eficiente e orientada por dados objetivos.

Palavras-chave: TDAH, Atenção, Rastreamento ocular, ODS 3.

Abstract

Attention Deficit Hyperactivity Disorder (ADHD) is a neuropsychological condition that can significantly affect children's performance in various spheres of life, such as studies and interpersonal relationships. Traditional diagnosis involves clinical assessments and standardized tests, which are not always readily available or present sufficient objective data for effective initial screening. This study proposes a technological approach that integrates a gamified digital platform, based on the Continuous Performance Test (CPT), with real-time eye-tracking techniques. The proposal aims to identify possible signs of ADHD in children aged 10 to 12 years through the analysis of attentional performance during the execution of gamified tasks. The system records

data such as correct answers, reaction time, omission and commission errors, variability in responses, and eye fixation patterns, which are processed automatically. Based on a comparison between the collected data and the database, the system provides interpretive feedback to the user, and can contribute as a complementary tool for initial screening. The accessibility of the platform, which runs directly in the browser, and its playful and autonomous nature make the solution promising for expanding access to early screening for signs of the disorder. The proposal is aligned with the third Sustainable Development Goal (SDG) of the UN's 2030 Agenda, which aims to ensure health and well-being for all people, promoting technological innovations for more inclusive, efficient and data-driven healthcare.

Palavras-chave: ADHD, Attention, Eye Tracking, SDG 3.

1 Introdução

A Organização das Nações Unidas (ONU) estabelece, por meio da Agenda 2030, metas para promover o desenvolvimento sustentável e o bem-estar global. Entre os 17 Objetivos de Desenvolvimento Sustentável (ODS), o terceiro busca garantir saúde de qualidade e promover o bem-estar para todos. Nesse contexto, este trabalho visa contribuir para essa meta ao propor uma solução tecnológica voltada à identificação de indícios do Transtorno de Déficit de Atenção com Hiperatividade (TDAH) em crianças entre 10 e 12 anos. [1]

O TDAH é uma condição neurobiológica de causas genéticas, que afeta milhões de pessoas em todo o mundo. É caracterizada por sintomas de desatenção, impulsividade, e, em alguns casos, hiperatividade, afetando significativamente o desempenho acadêmico, profissional e social dos afetados. Embora o diagnóstico clínico do TDAH seja baseado tradicionalmente em entrevistas e questionários subjetivos, avanços tecnológicos têm permitido o uso de ferramentas mais robustas e quantitativas para apoiar esse processo. [2] Entre essas ferramentas, destaca-se o *eye tracking* (do português, rastreamento ocular), trata-se de uma técnica que consiste em usar o posicionamento dos olhos de uma pessoa para obter informações sobre onde ela está olhando. Isso pode ser feito usando luzes infravermelhas, que calculam exatamente onde a pessoa está olhando com base nas reflexões da luz na retina, ou por meio de câmeras que monitoram visualmente a posição dos olhos e identificam sua direção.

Em ambientes controlados, o teste com eye tracking envolve a realização de tarefas padronizadas, nas quais o comportamento visual do participante é monitorado sem interferência direta de um moderador. Essa abordagem objetiva permite uma coleta mais confiável de dados, reduzindo o viés associado ao autorrelato e aumentando a credibilidade da análise. Além disso, a comparação dos dados obtidos com padrões normativos permite identificar desvios significativos no desempenho visual atencional, muitas vezes imperceptíveis a métodos tradicionais.

Quando aplicada em um teste diagnóstico, a técnica permite acompanhar com precisão os movimentos dos olhos de um indivíduo durante a realização de tarefas específicas, fornecendo dados objetivos e detalhados sobre onde, por quanto tempo e em que sequência uma pessoa fixa seu olhar em determinados estímulos visuais. Estudos demonstram que pessoas com TDAH apresentam menor tempo de fixação e padrão visual mais disperso ao realizarem testes de desempenho, sugerindo dificuldade em manter a atenção sustentada e filtragem de estímulos irrelevantes [3].

A Inteligência Artificial (IA) surge como um campo essencial nesse contexto, voltado à criação de sistemas capazes de simular aspectos da cognição humana, como percepção, raciocínio, aprendizado e tomada de decisão. Segundo [4], a IA pode ser dividida em dois tipos: IA Forte, capaz de compreender e raciocinar de forma semelhante aos humanos; e IA Fraca, restrita à

execução de tarefas específicas sem capacidade de raciocínio autônomo. O avanço dessas tecnologias, apoiado por algoritmos de aprendizagem profunda, processamento de linguagem natural e análise de dados, tem permitido desenvolver sistemas cada vez mais precisos e adaptativos.

Associada à IA, a Internet das Coisas (Internet of Things, IoT) amplia o potencial de integração tecnológica ao conectar dispositivos físicos, como sensores e equipamentos inteligentes, à internet. Essa interconexão possibilita a coleta, o compartilhamento e a análise de dados em tempo real, criando ecossistemas inteligentes baseados em computação em nuvem e comunicação entre máquinas. [5]

O Teste de Desempenho Contínuo (TDC) é uma medida padronizada amplamente utilizada na neuropsicologia para avaliar métricas de atenção sustentada, impulsividade, tempo de resposta e variabilidade dos tempos de reação. Trata-se de uma tarefa computadorizada na qual o usuário responde e reage a estímulos apresentados sequencialmente, permitindo medidas de desempenho atencional ao longo do tempo. A atenção é um processo cognitivo complexo que envolve diferentes componentes inter-relacionados, essenciais para o desempenho em tarefas como o teste de desempenho contínuo. De forma geral, pode ser classificada em quatro tipos principais. A atenção sustentada refere-se à capacidade de manter o foco em um estímulo ou tarefa por um período prolongado, sendo fundamental para evitar erros de omissão no TDC. A atenção seletiva envolve a habilidade de concentrar-se em informações relevantes enquanto se ignora distrações, o que influencia diretamente a precisão das respostas. A atenção alternada diz respeito à flexibilidade cognitiva para mudar o foco entre diferentes estímulos ou tarefas, demonstrando controle executivo. Por fim, a atenção dividida representa a capacidade de processar simultaneamente múltiplas fontes de informação, exigindo coordenação eficiente de recursos cognitivos. A compreensão dessas modalidades permite interpretar de forma mais abrangente as métricas obtidas no TDC. [6]

Os *serious games* (jogos sérios) também vêm se destacando como ferramentas complementares em contextos de avaliação e reabilitação cognitiva. Esses jogos digitais, desenvolvidos com finalidades que vão além do entretenimento, oferecem ambientes interativos e imersivos que aumentam o engajamento do usuário e permitem mensurar habilidades cognitivas de forma dinâmica.

Desta forma, a integração entre eye tracking, IA e jogos sérios representa uma abordagem promissora para a triagem e o apoio diagnóstico do TDAH. A análise dos dados com IA pode indicar o grau de desatenção apresentado por um indivíduo em diferentes contextos e contribuir para decisões clínicas mais embasadas. Assim, este estudo propõe o desenvolvimento de um software gamificado que utilize informações de rastreamento ocular processadas com base nas métricas do TDC, a fim de gerar um indicador do desempenho atencional geral e oferecer uma possível estimativa preliminar para o Transtorno de Déficit de Atenção com Hiperatividade.

2 Objetivo

Desenvolver uma plataforma digital gamificada, acessível por navegador, que utiliza rastreamento ocular e métricas de desempenho atencional para auxiliar na triagem inicial de indícios do TDAH em crianças de 10 a 12 anos.

OBJETIVOS ESPECÍFICOS

- Integrar o TDC a um jogo digital com tarefas que simulam desafios atencionais.
- Aplicar técnicas de *eye tracking* em tempo real para registrar padrões de atenção durante a execução das tarefas.
- Processar automaticamente os dados coletados e compará-los com parâmetros normativos para gerar feedback ao usuário.

- Ferramenta de auxílio ao pré-diagnóstico de TDAH, utilizada por profissionais da saúde como complemento na análise clínica.
- Promover uma solução acessível e alinhada ao ODS 3 da ONU, que amplie o acesso à triagem inicial de TDAH.

3 Estado da Arte

O diagnóstico do TDA em adultos continua sendo um desafio clínico significativo. Tradicionalmente, o processo diagnóstico baseia-se em entrevistas e testes clínicos, autorrelato e relatos de informantes, instrumentos que, embora úteis, podem ser afetados por viés retrospectivo, subjetividade do paciente, e simulação dos testes, resultando em casos de falsos positivos ou negativos. Dessa forma, o interesse por abordagens objetivas e tecnologicamente assistidas, que combinem dados neuropsicológicos e comportamentais com técnicas de análises automatizadas, aumentou. Estudos recentes têm investigado o uso de jogos digitais sérios como ferramentas de avaliação e treinamento cognitivo, com foco na atenção contínua. [7] exploraram a relação entre a prática regular de videogames e o desempenho em atenção sustentada, avaliado pelo *Conners' Continuous Performance Test II* (CPT II), uma versão amplamente utilizada do TDC. Embora não tenham encontrado diferenças de performance entre jogadores de videogames de ação, não ação e não jogadores, os autores identificaram o sexo como uma variável relevante, pois notaram diferença entre tempo de reação e número de erros. O estudo destaca a complexidade das interações entre fatores individuais e experiências digitais, sugerindo que a aplicação de jogos, mesmo quando classificados como *serious games*, precisam de cuidados na metodologia e no controle de variáveis, com o fim de evitar interferências no desempenho atencional.

Nesse contexto, [8] exploraram o potencial diagnóstico da integração entre o *MOXO-dCPT* (um TDC com fases estruturadas de distrações auditivas e visuais) e dados de *eye tracking*. O estudo contou com uma amostra de 85 adultos (43 com diagnóstico formal de TDA e 42 controles saudáveis) e analisou o padrão de atenção visual ao longo de diferentes partes do teste. Os resultados demonstraram que indivíduos com TDA apresentaram maior tempo de fixação em áreas irrelevantes da tela, particularmente em condições com distrações visuais, o que os autores interpretaram como uma medida direta de distratibilidade atencional objetiva. Essa métrica comportamental demonstrou maior poder discriminativo em comparação às melhores pontuações tradicionais do *MOXO*. Além disso, os autores propuseram que as partes do teste com distrações visuais poderiam ser utilizadas isoladamente, reduzindo o tempo do teste e mantendo a precisão.

Avançando nesse campo, [9] criaram uma solução diagnóstica que envolve um ambiente de realidade virtual (VR), onde os participantes realizavam um teste de desempenho imersivo sob a ocorrência de distrações simuladas em um ambiente 3D. Durante a tarefa, foram coletados dados simultâneos de *eye tracking*, movimentos da cabeça, eletroencefalograma (EEG) e desempenho atencional. O modelo de IA foi treinado em um conjunto de 50 participantes e testado de forma independente em outro conjunto de 36 indivíduos. O modelo final, com apenas 11 variáveis selecionadas, alcançou 81% de acurácia, 78% de sensibilidade e 83% de especificidade no conjunto de teste.

Os estudos indicam que a utilização de tecnologias de rastreamento ocular, tarefas cognitivas com análises embasadas dos dados representam um avanço significativo em relação aos métodos tradicionais de diagnóstico. O uso de *serious games* para coleta de dados de desempenho também é eficaz, como mostra o trabalho de [7]. O trabalho de [8] oferece um modelo aplicável e eficiente ao integrar *eye tracking* em um teste comercial já existente, o estudo de [9] diferencia a proposta ao incorporar realidade virtual, aprendizado de máquina e validação externa em amostras independentes. Juntos, os estudos reforçam a ideia de que sistemas digitais automatizados podem melhorar a precisão diagnóstica do TDA.

4 Metodologia


A *landing page* do projeto foi desenvolvida em *HTML*, responsável pela estrutura do conteúdo, *CSS*, utilizado para o estilo visual, e *JavaScript*, empregado na implementação da interatividade e do dinamismo da navegação. O sistema de rastreamento ocular foi implementado em *JavaScript*, utilizando a biblioteca *WebGazer.js*, que contém um modelo capaz de se autocalibrar ao observar a interação dos visitantes com a página, treinando um mapeamento entre as características do olhar e as posições na tela [10]. O tratamento das coordenadas oculares recebidas do *frontend* foi realizado em *JavaScript*, com o uso do *Node.js* e do *Socket.IO*, possibilitando a comunicação em tempo real com o *frontend*, uma vez que depende das coordenadas enviadas por ele. O *backend* é responsável por analisar as métricas TDC, dados que serão utilizados para compor o feedback individual de cada usuário. A biblioteca *serialport* gerencia a comunicação serial pela porta COM¹, enviando comandos ao dispositivo *IoT* e recebendo eventos, integrados ao *frontend* em tempo real via *Socket.IO*. Por fim, o jogo *web* foi desenvolvido em *TypeScript*, utilizando o *framework* *Next.js*, o que proporcionou um código mais robusto, organizado e uma experiência de uso moderna e fluida.

Optou-se pelo *MongoDB* em razão do elevado volume e da flexibilidade dos dados de rastreamento ocular. O formato em documentos facilita o registro sequencial das fixações e dos atributos relacionados sem a exigência de esquemas rígidos. O gerenciamento dos dados foi realizado com o *MongoDB Compass*.

Durante toda a experiência, o rastreamento ocular é realizado em segundo plano, utilizando a *WebGazer.js*, desenvolvida por pesquisadores da Universidade de Brown, nos Estados Unidos, para capturar os pontos de fixação visual do usuário. Para garantir a precisão da predição do olhar, a *WebGazer.js* utiliza uma arquitetura que combina diferentes técnicas de Aprendizado de Máquina. Inicialmente, o *TensorFlow FaceMesh* é mobilizado para a detecção precisa e em tempo real da face e, especificamente, dos pontos de referência da região ocular.

¹Porta de comunicação serial virtual que o computador utiliza para trocar dados com a placa Arduino através do cabo USB.

Figura 1: TensorFlow FaceMesh



(Google Developers, 2026)

O modelo de predição propriamente dito é baseado na Regressão Ridge. A principal função desta técnica é atuar como um mecanismo de regularização, que, simplificada, evita o superajustamento (*overfitting*) do modelo. Isso significa que ela impede que o modelo fique muito focado nos dados de treinamento, o que faria com que ele errasse ao lidar com novos usuários. A Regressão Ridge faz isso aliviando a influência dos parâmetros de maior valor no aprendizado. O resultado é um modelo mais robusto e generalizável, capaz de realizar o mapeamento entre a imagem dos olhos e as coordenadas da tela de forma confiável para diferentes participantes.

$$RSS_{L2} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \lambda \sum_{j=1}^P \beta_j^2 \quad (1)$$

A fórmula apresentada detalha como o modelo calcula o seu desempenho e define a configuração otimizada para a predição. O termo RSS_{L2} representa a Soma dos Quadrados dos

Resíduos, que é a pontuação de erro do modelo. O objetivo da Regressão Ridge é fazer com que esse valor seja o menor possível através de dois componentes principais. O erro residual $Y_i - \hat{Y}_i$, que consiste na diferença entre onde o usuário realmente olhou Y_i e onde o algoritmo previu que ele olhou $\hat{Y}_i$. Eleva-se essa diferença ao quadrado para que erros grandes sejam mais penalizados do que erros pequenos, garantindo que o modelo busque a maior precisão possível. O termo de penalidade $\lambda \sum B_j^2$, componente que impõe uma restrição aos coeficientes B , que representam a relevância atribuída a cada ponto de referência facial extraído da imagem capturada pela webcam. Sem essa restrição, o modelo poderia atribuir importância excessiva a ruídos, como variações de iluminação ou sombras. E por fim, o hiperparâmetro λ , um número definido previamente que controla o rigor dessa restrição. Se o modelo tentar dar importância demais a um detalhe irrelevante, o λ aumenta o peso desse erro, forçando os coeficientes B a diminuírem. Ao ponderar esses componentes, o sistema controla o fenômeno do *overfitting* visto que em vez de ajustar-se estritamente às particularidades e ruídos dos dados de calibração momentâneos o algoritmo estabelece um modelo de predição generalizável. [11]

Finalmente, no pós-processamento, as predições de olhar bruto são submetidas ao Filtro de Kalman, um algoritmo recursivo que suaviza os dados para corrigir as falhas naturais da webcam. A principal função desse filtro é oscilações ou tremores que acontecem no ponto de fixação mesmo quando o usuário está com o olhar parado. O resultado é um rastro de olhar natural e contínuo, [12]. É importante notar que todos os componentes algorítmicos, incluindo *FaceMesh*, Regressão Ridge e Filtro de Kalman, são nativos da biblioteca *WebGazer.js* e foram empregados em sua configuração padrão, sem modificações.

Para a hospedagem e sustentação da infraestrutura do sistema, utilizou-se a plataforma *Google Cloud Platform* (GCP), uma provedora de serviços de computação em nuvem que oferece escalabilidade, segurança e alta disponibilidade para aplicações web. A seleção da GCP justificou-se pela familiaridade técnica da equipe de desenvolvimento com o ecossistema da provedora, bem como pela otimização dos custos de implantação disponibilizada pelo programa de créditos iniciais para novos projetos. O ecossistema foi estruturado por meio de uma *VPC Network*, denominada *focusquest-vpc*, integrada a um *Serverless VPC Connector* para garantir o isolamento e o tráfego seguro entre os componentes. O ambiente computacional baseou-se na arquitetura *serverless* do *Cloud Run* para a execução do *frontend* e do *backend* com balanceamento de carga automático. Para o gerenciamento de estado e persistência, integrou-se o banco de dados externo *MongoDB Atlas* como repositório principal, apoiado por uma instância do *Memorystore for Redis* para cache. O armazenamento de arquivos, *backups* e *logs* foi centralizado em buckets estruturados no *Cloud Storage* com políticas de versionamento ativas. Por fim, a segurança das credenciais e variáveis sensíveis foi gerenciada de forma centralizada pelo *Secret Manager*, enquanto a integridade operacional, automação de *deploy* e observabilidade do sistema foram garantidas pelas ferramentas *Cloud Build*, *Cloud Monitoring* e *Cloud Logging*.


A plataforma foi desenvolvida com tecnologias web, possibilitando acesso remoto e execução direta em navegadores, preferencialmente com a webcam *Logitech C270*, por apresentar melhor qualidade na captura do olhar. Optou-se pela plataforma *web* considerando-se múltiplos fatores: a estabilidade do equipamento durante a calibração e execução das fases do jogo; o contexto de uso destinado a crianças, para o qual um dispositivo móvel poderia resultar em desatenção ou menor comprometimento, ao ser confundido com uma atividade comum de entretenimento; a temática espacial com abundância de elementos visuais, que exigiria redução dimensional em telas móveis, prejudicando a disposição adequada dos elementos; e, finalmente, o contexto de aplicação por profissionais em ambientes de escritório, onde notebooks são mais disponíveis. O teste é executado em ambiente silencioso, sob supervisão de profissional responsável pela preparação do ambiente, criação do perfil da criança e orientação do procedimento, conforme as instruções disponibilizadas pela plataforma.

O estudo é estruturado como um jogo digital de temática espacial guiado por rastreamento ocular, composto por três fases com níveis crescentes de dificuldade. O jogo será aplicado por

profissionais da saúde, como psicólogos, para a triagem inicial de indícios de TDAH em crianças entre 10 e 12 anos. A mecânica do jogo foi elaborada para simular os princípios do TDC, promovendo a exposição contínua a estímulos visuais por períodos prolongados e exigindo respostas rápidas e consistentes por parte do participante através do olhar, em consonância com paradigmas de avaliação de inibição de resposta e controle atencional em crianças [13]. Além disso, aplicou-se o princípio de avaliação de atenção sustentada proposto em [14]. Nele, a tarefa consiste na observação de estímulos sequenciais com respostas condicionadas a sinais-chave, dinâmica que foi devidamente adaptada e distribuída entre as três fases do sistema. Os dados de fixação visual coletados permitem identificar padrões de atenção ou desatenção, que são contrastados com nossa base de dados em cada etapa da atividade. Todas as fases do experimento são configuradas para potencializar a sobrecarga sensorial e dificultar a concentração do participante. Para tal, utilizam-se música de fundo, cuja intensidade e ritmo são ajustados conforme o nível de dificuldade, e a imposição de um tempo máximo definido, elementos que, em conjunto, intensificam o estresse cognitivo e a exigência da tarefa. O ambiente de teste é controlado, com supervisão profissional, o que garante a padronização das condições de aplicação e a segurança dos participantes.


O profissional, já com cadastro e login previamente definidos na plataforma, assim como a criação do perfil do paciente que irá jogar, pode acessar o sistema. O participante é direcionado para a página de instruções, onde são apresentadas a sequência de como calibrar o olhar para poder prosseguir para o jogo.

Figura 2: Calibração do olhar



Autoria Própria (2026)

Figura 3: Ilustração da calibração do olhar



Autoria Própria (2026)

A calibração é realizada antes do início do jogo, de modo que o sistema ajuste o mapeamento entre as características do olhar e as posições na tela. O procedimento inclui nove pontos de fixação (estrelas) dispostos em uma grade 3×3 . O participante é instruído a fixar o olhar em cada ponto por cerca de cinco segundos e a posicionar o cursor sobre a estrela, clicando nela até que esta desapareça. Simultaneamente, o sistema registra as coordenadas oculares. Esse procedimento é essencial para compensar variações individuais na anatomia, postura e distância da câmera, garantindo maior precisão do rastreamento. Concluída a calibração, o sistema encontra-se apto a interpretar os movimentos oculares durante as fases do jogo.

Antes de cada fase, existem as instruções da mesma. Em seguida, o usuário inicia a primeira etapa do teste.


Figura 4: Primeira fase



Autoria Própria (2026)


Na primeira fase, o participante deve fixar o olhar por cinco segundos em cinco alvos estáticos, representados por estrelas, enquanto elementos animados surgem ao redor. Após os cinco segundos, cada estrela desaparece da tela. A música de fundo apresenta ritmo moderado e a duração total da fase é de um minuto. O objetivo é avaliar a capacidade de manter a atenção em um ponto fixo, inibindo a resposta a estímulos visuais e auditivos periféricos. Nesta fase, foram aplicados procedimentos de atenção sustentada e atenção seletiva. Ao fim da fase, o participante pode visualizar seu desempenho, conforme ilustrado na Figura 5.

Figura 5: Resultados da fase 1



Autoria Própria (2026)

Figura 6: Segunda fase



Autoria Própria (2026)

Na segunda fase, o participante deve manter o foco em cinco estrelas estáticas, que brilham alternadamente (estímulo primário). Simultaneamente, três planetas em movimento transitam pela tela, atuando como distratores (estímulos secundários) cuja presença não é mencionada nas instruções. A trilha sonora, mais intensa e acelerada nesta fase, eleva a carga cognitiva e

permite observar o impacto de múltiplos estímulos simultâneos na manutenção da atenção. A fase 2 é composta por duas rodadas iguais de 15 segundos cada, nas quais apenas os planetas exibidos são alterados. Ao término de cada rodada, o participante é submetido a um teste de reconhecimento: sete opções de planetas são apresentadas, sendo que apenas três transitaram na tela. O participante deve indicar, por meio de botões *IoT*, quais planetas foram reconhecidos durante o trânsito.

Figura 7: Pergunta da segunda fase




Autoria Própria (2026)

Nesta etapa, pode-se citar semelhança ao teste realizado em [15]. Nesse teste, a instrução inicial é contar quantos passes de bola o time de branco realiza, ao final, após a resposta, uma pergunta adicional questiona se o participante observou uma distração (urso dançando) durante o jogo de basquete. Dessa forma, o participante não procura pela distração, mas, caso consiga detectá-la, infere-se que impacta positivamente no pré-diagnóstico, pois a instrução inicial direcionava o foco para os alvos, tornando a distração menos atraente.

O reconhecimento correto de planetas efetivamente exibidos é contabilizado como acerto, enquanto a seleção de planetas não exibidos configura erro. Dessa forma, ao final da fase, são exibidas a quantidade de acertos, os planetas vistos e os planetas ignorados. O objetivo é avaliar a capacidade da criança de reconhecer os estímulos não citados nas instruções.


Figura 8: Resultado da segunda fase



Autoria Própria (2026)

A percepção dos planetas é tratada como um dado positivo para a inferência do pré-diagnóstico, pois contribui para a classificação do desempenho atencional da criança em relação aos resultados esperados. Por sua vez, a ausência de reconhecimento desses estímulos é considerada um dado complementar que também compõe a análise final, porém, negativamente. Nesta fase, foram aplicados procedimentos de atenção sustentada.

Para a construção do dispositivo de controle *IoT*, foram empregados os seguintes componentes eletrônicos: uma placa de desenvolvimento Arduino, sete botões do tipo *push-button*, sete resistores de 10 k Ω , três protoboard e cabos de conexão. Os botões foram conectados às portas digitais do Arduino, configuradas como entradas com resistores pull-down para garantir leituras estáveis. Dessa forma, ao término de cada rodada da segunda fase do jogo, o participante registra os planetas que conseguiu observar, pressionando o botão correspondente a ele. O Arduino atua como uma interface de comunicação de hardware, detectando o pressionamento físico dos botões *IoT*. Por meio da comunicação serial, o microcontrolador transmite o evento acionado ao sistema. O servidor é responsável por receber e interpretar este sinal do botão selecionado e, na sequência, acionar a função que contabiliza os acertos e os erros de inibição do participante para a fase.

Figura 9: Controle *IoT*

Autoria Própria (2026)

Para o aperfeiçoamento estético e ergonômico do controle, os botões convencionais foram substituídos por peças personalizadas, fabricadas via impressão 3D e customizadas com adesivos ilustrativos dos planetas da fase 2, resultando em um design mais atrativo para o público infantil. Entretanto, ainda planeja-se construir uma case para o controle utilizando filamentos de garrafa PET, visando a sustentabilidade ambiental do projeto e otimização ergonômica.


Figura 10: Terceira fase



Autoria Própria (2026)

Na terceira fase, a demanda cognitiva é intensificada pela necessidade de alternância rápida do foco visual entre diferentes regiões da tela. Nessa etapa, uma estrela surge brilhando por 15 segundos, e o participante deve manter o olhar fixo sobre ela durante esse tempo. Ao final desse intervalo, surge um segundo alvo: o radar de uma aeronave, que permanece ligado por mais 15 segundos. O intuito é que a criança perceba esse radar aceso e direcione o olhar para ele. A duração total desta fase é de 30 segundos. A trilha sonora atinge seu nível máximo de intensidade e agitação, contribuindo para aumentar a complexidade da tarefa. O desempenho do participante nesta fase é utilizado como indicador da agilidade atencional e da capacidade de redirecionamento e manutenção do foco visual diante de estímulos dinâmicos. Ao fim da terceira fase, métricas como número de acertos (fixação por 5 segundos), número de erros de omissão (demora 15 segundos para iniciar a fixação) e erros de comissão (início da fixação antes de 15 segundos, sem manutenção do foco por 5 segundos) são calculados e apresentados ao participante, conforme ilustrado na Figura 11.


Figura 11: Resultado da terceira fase



Autoria Própria (2026)

Ao término das três fases, o sistema gera uma estimativa de desempenho atencional com base nas métricas TDC. Para isso, são utilizados os registros de desempenho e os dados mais recentes de rastreamento ocular obtidos durante as fases, sendo eles: acertos, erros de omissão, erros de comissão, tempo de resposta e desvio padrão. Este pré-diagnóstico é elaborado por um módulo de inteligência artificial desenvolvido como um microserviço independente, responsável por interpretar as métricas consolidadas e classificar o desempenho do participante em duas categorias: *positive*, quando o padrão de atenção observado indica um desempenho satisfatório, ou *negative*, quando os indicadores apontam maior comprometimento atencional. O feedback resultante é apresentado em duas formas: (1) uma mensagem textual interpretativa, como: “Sua atenção está conforme o esperado”, “Sua atenção está acima do esperado” ou “Sua atenção está abaixo do esperado”, de acordo com o desempenho observado; e (2) a exibição de uma porcentagem que representa a confiança da predição produzida pelo modelo, conforme ilustrado na Figura 12.

Figura 12: Pré-diagnóstico



Autoria Própria (2026)


A modelagem dessa etapa de inteligência artificial foi construída a partir da consolidação das informações armazenadas no banco de dados. Para o treinamento do classificador, foi criado um conjunto de dados final com uma linha por usuário ou sessão, integrando métricas das fases do experimento. Assim, o modelo opera sobre atributos resumidos do comportamento visual do participante, como tempo médio de reação, desvio padrão, número de acertos, erros de comissão, erros de omissão e taxa de acerto.

Antes do treinamento, os atributos são organizados e aplica-se o *StandardScaler* para normalização das variáveis. O classificador utilizado é uma *Random Forest* com 100 árvores, treinada com divisão de 80% para treino e 20% para teste, além de validação cruzada estratificada com a métrica *ROC-AUC* quando há quantidade suficiente de amostras por classe. No final, o modelo, o escalador e a definição das características são salvos no sistema de armazenamento.

A predição ocorre por meio de um serviço *REST* implementado em *FastAPI*, executado em um contêiner separado e exposto no endpoint `/predict`. Esse serviço recebe as métricas agregadas, aplica o escalonamento e calcula a probabilidade de classificação positiva. A decisão final é obtida por um limiar de 0,5. A comunicação entre o *backend* principal e o módulo de IA ocorre por requisição *HTTP*; ao final da fase 3, o servidor reúne as métricas das três fases e as envia ao serviço, que retorna a avaliação final para armazenamento e exibição ao usuário.

Considerando a análise realizada pelo profissional e os resultados a serem apresentados aos pais ou responsáveis, o pré-diagnóstico é disponibilizado em relatório com linguagem clara, acessível e visualmente intuitiva. A mensagem interpretativa é redigida sem termos técnicos, de modo a oferecer uma avaliação direta do desempenho da criança em relação aos padrões esperados. A Figura 13 exemplifica o layout e o conteúdo do relatório gerado pelo sistema, que visa facilitar a compreensão dos resultados e orientar as decisões futuras.

Figura 13: Relatório de Pré-diagnóstico



Autoria Própria (2026)

Com o objetivo de aprofundar a compreensão do tema e promover um alinhamento mais preciso entre os aspectos técnicos e psicológicos do projeto, foi conduzida uma pesquisa de campo com quatro profissionais da área da Psicologia. As entrevistas buscaram avaliar a viabilidade técnica da proposta, identificar os sintomas mais recorrentes do TDAH e compreender os tipos de estímulos que mais influenciam os processos de distração em indivíduos com esse transtorno.

As entrevistas realizadas com os profissionais revelaram que estímulos visuais e auditivos, especialmente movimento, cor e som, exercem papel determinante na indução de distrações nos seus pacientes, devendo, portanto, ser considerados elementos centrais no planejamento das fases experimentais. Adicionalmente, pode-se citar a instrução de avisar os jogadores sobre as distrações. Nas fases um e três, durante as instruções, os participantes são avisados sobre os distratores e orientados a não olhar para eles, pois esta ação impacta negativamente a pontuação, já que o objetivo dessas fases é que a criança mantenha o foco nos alvos, ignorando os distratores.


Além disso, os profissionais destacaram a importância de incluir uma etapa em que os distratores estejam presentes de forma indireta, sem que o participante seja instruído a focar neles. Sendo assim, na fase 2 do jogo, os planetas transitam pela tela sem que o participante seja instruído a observá-los.

A metodologia fundamenta-se na aplicação adaptada do TDC. A principal contribuição deste estudo consiste na integração do TDC ao rastreamento ocular em tempo real para avaliar o nível de atenção, o que contribui como auxílio ao pré-diagnóstico do TDAH. Ao registrar variáveis de olhar, por exemplo, duração de fixação, dispersão do olhar e tempo sobre alvos, busca-se complementar as medidas comportamentais do teste e aumentar a confiabilidade da avaliação. Essas medidas oculares apresentam menor dependência da resposta deliberada do participante, pois capturam sinais contínuos e fisiológicos da atenção que podem ser sincronizados com os eventos do exame. Dessa forma, é possível detectar padrões que contribuem com a interpretação clínica. Ressalta-se, contudo, que o rastreamento ocular é complementar e não substitui a

avaliação clínica.

Para uma melhor compreensão do funcionamento do sistema, a Figura 14 apresenta o fluxograma do processo, que descreve a sequência lógica das operações realizadas pelo sistema até o término das três partidas.

Figura 14: Fluxograma do sistema



Autoria Própria (2026)

Na etapa 1, ocorre a calibração dos olhos do jogador, processo em que o sistema identifica e ajusta os pontos de fixação ocular do usuário antes do início do jogo, garantindo a precisão do rastreamento. Em seguida, na etapa 2, há uma tomada de decisão para verificar se o participante irá jogar no modo de treinamento, o qual pode ser habilitado apenas pelo administrador quando houver necessidade de aumentar a base de dados. Na etapa 3, é executada a coleta das métricas TDC, que ocorre automaticamente durante as três fases do jogo. Nessa etapa, o sistema processa e registra parâmetros como número de acertos, erros de omissão, erros de comissão, tempo de reação e variabilidade temporal das respostas. Caso o modo de treinamento esteja habilitado, na etapa 4, o sistema armazena as métricas TDC em uma base de dados para permitir a retroalimentação da IA, que realiza a análise comparativa entre os dados do indivíduo e a base existente. Vale ressaltar que a etapa 4 será implementada em iterações futuras. Já na etapa 5, quando o modo de treinamento não está ativado, o sistema armazena as métricas TDC em uma base de dados para que a IA possa fazer a análise. Ao final, na etapa 6, o jogo exibe um feedback ao usuário, indicando o seu desempenho atencional.

Uma vez estabelecida a lógica de execução das etapas, a implementação técnica do sistema fundamenta-se em uma arquitetura cliente-servidor. Ao iniciar a fase 1, estabelece-se uma conexão via *WebSocket* entre o cliente e o servidor. Em seguida, o servidor identifica o cliente conectado, que envia as coordenadas das estrelas para o endpoint `/iniciar_fase1`. O processo de *eye tracking* é então iniciado, e o cliente passa a transmitir as coordenadas dos olhos a cada 1 segundo para `/gaze_data_fase1`. Paralelamente, o servidor seleciona uma das cinco estrelas como alvo atual, enquanto o cliente permanece em escuta por meio de `/fase1_iniciada`, responsável por destacar a estrela correspondente e manter o envio das coordenadas oculares. Esse procedimento se repete até que todas as estrelas sejam visualizadas por, no mínimo, 5 segundos, de modo que o participante fixe o olhar no alvo até sua desaparecimento da tela. Ao final da fase, o servidor salva o objeto `ExperimentosFase1Schema` no banco de dados, contendo as informações do paciente, a data e a hora do teste, um array do histórico de olhar da criança, com o alvo, as coordenadas e o estado de fixação, além de um array com o resultado de cada alvo, indicando métricas de tempo e o motivo do término. Após o armazenamento desses dados, o servidor calcula as métricas TDC da fase 1 e salva o objeto `EstatisticasFase1Schema` com: número de acertos (fixação por 5 segundos), número de erros de omissão (demora de 10 segundos ou mais para iniciar a fixação) e erros de comissão (início da fixação antes de 10 segundos, sem manutenção do foco por 5 segundos). Essas métricas são enviadas ao cliente por meio de `/fase_concluida`.

No início da fase 2, o servidor reconhece o cliente conectado, que apresenta estrelas piscando alternadamente enquanto planetas se movem pela tela. Ao final de cada rodada, o cliente envia ao servidor o comando de aguardo da resposta do usuário através do endpoint `/aguardando_iot`. O servidor, então, transmite a mensagem ao *IoT* e solicita que acenda um LED, indicando que o participante pode responder. O *IoT* acende o LED e faz a leitura dos botões pressionados pelo evento `button pressed`. A cada clique no botão correspondente ao planeta, o *IoT* utiliza a função do servidor que envia ao cliente o planeta clicado e se ele está correto ou não. Se o planeta estiver correto, ele é iluminado com a cor verde; caso contrário, é iluminado com a cor vermelha. O participante pode apertar três botões por rodada. Ao finalizar ambas as rodadas, o servidor envia ao cliente a quantidade de acertos, planetas vistos e planetas ignorados através de `/fase_atual_finalizada`.

Durante a fase 3, o servidor identifica o cliente conectado e recebe, por meio do endpoint `/iniciar_fase3`, a configuração dos alvos da etapa. Em seguida, o processo de *eye tracking* é iniciado, e o cliente passa a transmitir periodicamente as coordenadas dos olhos para `/gaze_data_fase3`. Paralelamente, o servidor percorre a sequência pré-definida da fase 3 e define o alvo atual em intervalos de 15 segundos, enquanto o cliente permanece em escuta por meio de `/fase3_iniciada` para destacar o alvo correspondente e manter o envio das coordenadas oculares. Durante a exibição de cada alvo, o servidor registra no histórico de olhar os eventos de

foco e desvio, que podem variar entre início de foco, foco finalizado, desvio por omissão ou por comissão. Também são calculados o tempo de reação, a duração máxima de foco, o desvio máximo e o tempo total focado, além da contabilização das ocorrências de comissão e omissão. Ao término de cada apresentação do alvo, seja por tempo esgotado, foco completo ou troca de alvo, o servidor salva o objeto `ExperimentosFase3Schema` no banco de dados, contendo as informações do paciente, a data e a hora do teste, um array do histórico de olhar da criança com o alvo, as coordenadas e o estado de fixação, além de um array com o resultado de cada alvo, indicando métricas de tempo e o motivo do término. Após o armazenamento desses dados, o servidor calcula as métricas TDC específicas da fase 3 e salva o objeto `EstatisticasFase3Schema` com tempo de reação médio e desvio padrão, número de acertos, número de erros de omissão e número de erros de comissão. Essas métricas são enviadas ao cliente por meio de `/fase_concluida`.

5 Resultados e Discussões

Os resultados apresentados referem-se à validação técnica do protótipo, uma vez que ainda não foi realizada validação clínica com amostras representativas.

O protótipo demonstrou funcionamento consistente em todas as etapas previstas. A calibração de nove pontos estabeleceu o mapeamento inicial do olhar em condições de iluminação controlada, e o módulo de captura ocular manteve o envio contínuo de coordenadas ao servidor durante a execução das fases. A comunicação via *WebSocket* suportou a sincronização necessária para destacar alvos e registrar fixações, enquanto a integração com o dispositivo *IoT* permitiu o acionamento correto do LED e a leitura dos eventos de pressão dos botões.

Durante os testes, o sistema registrou de forma estruturada as métricas previstas pelo protocolo adaptado do TDC: acertos, erros de omissão, erros de comissão, tempo de reação e variabilidade temporal das respostas. Esses dados são exibidos ao final de cada fase e consolidados em um relatório final. No entanto, foram identificadas limitações relevantes. O rastreamento ocular funcionou de forma estável, mas a precisão obtida ainda não é satisfatória para o uso adequado no contexto do projeto, sendo sensível a variações de iluminação e ao modelo de webcam utilizado. O módulo de IA foi implementado e treinado, porém com dados sintéticos e em volume reduzido, o que impede qualquer conclusão sobre sua eficácia real; a validação do modelo depende da coleta de dados com o público-alvo. Os próximos passos incluem coleta com participantes reais, anotação e ampliação da base de dados, refinamento da calibração e testes de usabilidade com o dispositivo *IoT*.

6 Conclusão

Este trabalho apresentou o desenvolvimento de uma ferramenta gamificada voltada ao auxílio do pré-diagnóstico de indícios de TDAH em crianças de 10 a 12 anos. A solução proposta conseguiu integrar tecnologias distintas, como rastreamento ocular, métricas TDC e dispositivos *IoT*, consolidando uma plataforma funcional para a análise do comportamento atencional.

Os resultados demonstram a viabilidade técnica da abordagem, uma vez que o sistema de rastreamento ocular apresentou precisão satisfatória para as demandas atuais e a coleta das métricas TDC mostrou-se adequada para o registro do desempenho dos participantes. O componente de *IoT* também operou de forma promissora, embora tenham sido identificadas oportunidades de melhoria na ergonomia do dispositivo físico. Atualmente, a consolidação definitiva do módulo de IA permanece vinculada ao refinamento da estabilidade dos dados oculares. Para superar essa limitação e aumentar a robustez da predição em diferentes condições de uso, o algoritmo de código aberto em *Python* [16] proposto por Jonathan Orlosky está sendo estudado e adaptado ao cenário deste projeto. Originalmente desenvolvido para sistemas baseados em óculos com câmaras integradas (*eye-tracking wearable*), o algoritmo está adaptado para operar utilizando uma webcam *Logitech C270* estática. Esse algoritmo baseia-se na extração de *facial landmarks*

e em modelos geométricos tridimensionais para estimar a orientação do olhar em tempo real, permitindo mapear as coordenadas oculares sem a necessidade de hardware especializado. Além deste, está sendo analisado o projeto de investigação científica desenvolvido pela NVlabs, departamento de pesquisa de inteligência artificial da NVIDIA, chamado **Few-Shot Gaze**. A proposta deste modelo é realizar um rastreamento ocular computado com poucos pontos de calibração utilizando imagens faciais, por meio de *deep learning*, o sistema reconstrói a imagem da face do usuário olhando para diferentes regiões da tela até que o modelo seja capaz de inferir a direção exata do olhar [17]. Ambos os projetos, embora ainda em fase de estudo, apresentam potencial para aprimorar a precisão e a estabilidade do rastreamento ocular, o que é fundamental para a eficácia do sistema como ferramenta de suporte ao pré-diagnóstico de TDAH.

A relevância deste estudo reside na criação de uma metodologia alternativa que pode oferecer aos profissionais da saúde dados quantitativos que complementam a observação clínica, sem finalidade de substituição dos métodos tradicionais. Como continuidade, pretende-se realizar validações em ambiente controlado com especialistas e o público-alvo, permitindo a consolidação do rastreamento ocular. Dessa forma, a inteligência artificial poderá ser treinada com um grande volume de dados para identificar padrões comportamentais específicos. Conclui-se que a proposta possui aplicabilidade prática e um potencial relevante como ferramenta de suporte ao pré-diagnóstico de indícios de TDAH, ao mesmo tempo que requer aprimoramentos incrementais para atingir maturidade.

Agradecimentos

Os autores agradecem à Faculdade de Tecnologia do Estado de São Paulo (FATEC) e ao Centro Paula Souza (CPS) pelo apoio institucional.

Referências

- [1] U. Nations, “Transforming our world: the 2030 agenda for sustainable development,” New York, 2015, accessed: 2025-10-28. [Online]. Available: <https://sdgs.un.org/sites/default/files/publications/21252030%20Agenda%20for%20Sustainable%20Development%20web.pdf>
- [2] M. da Saúde, “Transtorno do déficit de atenção com hiperatividade - tdah,” 2014. [Online]. Available: <https://bvsm.sau.gov.br/transtorno-do-deficit-de-atencao-com-hiperatividade-tdah/>
- [3] J. H. Yoo, C. Kang, J. S. Lim, B. Wang, C.-H. Choi, H. Hwang, D. H. Han, H. Kim, H. Cheon, and J.-W. Kim, “Development of an innovative approach using portable eye tracking to assist adhd screening: a machine learning study,” *Frontiers in Psychiatry*, vol. 15, 2024. [Online]. Available: <https://www.frontiersin.org/journals/psychiatry/articles/10.3389/fpsy.2024.1337595>
- [4] D. Cole, “The Chinese Room Argument,” in *The Stanford Encyclopedia of Philosophy*, Winter 2024 ed., E. N. Zalta and U. Nodelman, Eds. Metaphysics Research Lab, Stanford University, 2024.
- [5] IEEE, “Towards a definition of the internet of things (iot),” 2015. [Online]. Available: <https://iot.ieee.org/definition.html>
- [6] C. M. Cullum, “4.11 - neuropsychological assessment of adults,” in *Comprehensive Clinical Psychology*, A. S. Bellack and M. Hersen, Eds. Oxford: Pergamon, 1998, pp. 303–347. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/B0080427073002273>

- [7] L. M. Nascimento and C. B. Menezes, “A relação entre a prática regular de videogames e atenção sustentada,” *Ciências & Cognição*, vol. 25, no. 1, pp. 141–156, Dec. 2020. [Online]. Available: <https://revista.cienciasecognicao.org/index.php/cec/article/view/1661>
- [8] T. Elbaum, Y. Braw, A. Lev, and Y. Rassevsky, “Attention-deficit/hyperactivity disorder (adhd): Integrating the moxio-dept with an eye tracker enhances diagnostic precision,” *Sensors*, vol. 20, no. 21, 2020. [Online]. Available: <https://www.mdpi.com/1424-8220/20/21/6386>
- [9] A. Wiebe, B. Selaskowski, M. Paskin, L. Asché, J. Pakos, B. Aslan, S. Lux, A. Philipsen, and N. Braun, “Virtual reality-assisted prediction of adult adhd based on eye tracking, eeg, actigraphy and behavioral indices: a machine learning analysis of independent training and test samples,” *Translational Psychiatry*, vol. 14, no. 1, p. 508, 2024. [Online]. Available: <https://doi.org/10.1038/s41398-024-03217-y>
- [10] A. Papoutsaki, P. Sangkloy, J. Laskey, N. Daskalova, and J. Huang, Jeff e Hays, “Webgazer: Rastreamento ocular escalável via webcam usando interações do usuário,” in *Anais da 25ª Conferência Internacional Conjunta sobre Inteligência Artificial (IJCAI)*, Jul. 2016. [Online]. Available: <https://webgazer.cs.brown.edu/>
- [11] J. Murel and E. Kavlakoglu, “O que é a regressão ridge?” 2024. [Online]. Available: <https://www.ibm.com/br-pt/think/topics/ridge-regression>
- [12] Brown HCI Group, “Webgazer.js: 3.2 gaze prediction,” 2024, documentação Wiki. [Online]. Available: <https://deepwiki.com/brownhci/WebGazer/3.2-gaze-prediction>
- [13] C. P. Hoyniak and I. T. Petersen, “A meta-analytic evaluation of the n2 component as an endophenotype of response inhibition and externalizing psychopathology in childhood,” *Neuroscience & Biobehavioral Reviews*, vol. 103, pp. 200–215, 2019. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0149763418307243>
- [14] ScienceDirect, “Continuous performance task,” 2016. [Online]. Available: <https://www.sciencedirect.com/topics/neuroscience/continuous-performance-task>
- [15] GeniumSoft, “Teste de atencao - legendado,” 2009. [Online]. Available: <https://www.youtube.com/watch?v=FzeXeXR9cCs>
- [16] J. Orlosky, “EyeTracker: A lightweight and robust Python eye tracker,” 2024. [Online]. Available: <https://github.com/JEOresearch/EyeTracker>
- [17] S. Park, S. De Mello, P. Molchanov, U. Iqbal, O. Hilliges, and J. Kautz, “Few-shot adaptive gaze estimation,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 9368–9377. [Online]. Available: https://github.com/NVlabs/few_shot_gaze